

شرح خوارزمية DCGAN

الشبكة التوليدية التنافسية الالتفافية العميقة — Deep Convolutional GAN


١. الفكرة الأساسية

تتنافسان مع بعضهما في لعبة مستمرة، حتى تصل إحداها إلى مستوى عال من الإتقان في توليد صور تشبه الصور الحقيقية. خوارزمية DCGAN تعتمد على شبكتين عصبيتين

المهمة	الشبكة
يحول ضوضاء عشوائية إلى صورة مزيفة	المولد (Generator)
يحاول التفريق بين الصورة الحقيقية والمزيفة	المميز (Discriminator)

٢. مخطط تدفق الخوارزمية الكامل


الذي ينتج صورة مزيفة، وصولاً إلى المميز الذي يقارن هذه الصورة بصورة حقيقية من قاعدة البيانات ويصدر قراره النهائي. يوضح المخطط التالي الرحلة الكاملة: من الضوضاء العشوائية، مروراً بالمولد



البيانات في DCGAN — الضوضاء تتحول إلى صورة عبر المولد، والمميز يفحص كلا النوعين من الصور (حقيقية ومزيفة) ليصدر قراره. الشكل ١: تدفق

٣. المولد (Generator) — كيف يبني الصورة؟

طبقات الالتفاف المعكوس (Conv2DTranspose) التي تزيد الأبعاد المكانية خطوة بخطوة بينما تقلل عدد القنوات. مهمة المولد هي تكبير متجه صغير من الأرقام العشوائية تدريجيا حتى يصبح صورة كاملة، وذلك باستخدام




طبقة Dense وإعادة تشكيل، ثم ثلاث طبقات Conv2DTranspose متتالية تكبر الصورة من 7×7 إلى 14×14 ثم 28×28 بيكسل. الشكل ٢: بنية المولد — من متجه ضوضاء بحجم 100 رقم، عبر

دور كل مكون في المولد:

- Dense Layer: $256 \times 7 \times 7$ مصفوفة (يسقط متجه الضوضاء على حجم صغير قابل لإعادة التشكيل كخريطة ميزات مصفوفة).
- Reshape: (يحول المتجه المسطح إلى مصفوفة ثلاثية الأبعاد (ارتفاع $\times$ عرض $\times$ قنوات).
- Conv2DTranspose: أي تكبير الدقة المكانية بدلا من تصغيرها، وبذلك يتعلم كيف "يرسم" التفاصيل تدريجيا.
- Batch Normalization: يقوم بعملية "الالتفاف المعكوس"، يثبت توزيع القيم بعد كل طبقة، مما يسرع التدريب ويقلل من مشكلة انهيار الأنماط (Mode Collapse).
- ReLU: يضيف اللاحظية في الطبقات الوسيطة ليتمكن المولد من تعلم تحويلات معقدة.
- Tanh (الطبقة الأخيرة): يحصر قيم البيكسل الناتجة بين -1 و 1، بما يطابق طريقة تطبيع الصور الحقيقية أثناء التدريب.

٤. المميز (Discriminator) — كيف يصدر قراره؟

التفافية (CNN) عادية، لكنه بدل تصنيف الأشياء إلى فئات متعددة، يخرج احتمالا واحدا فقط: هل الصورة حقيقية أم مزيفة؟ المميز في جوهره هو مصنف صور مبني على شبكة



لاستخراج الميزات المكانية، ثم تسطح وتمر عبر طبقة Dense واحدة، وأخيرا دالة Sigmoid تعطي احتمال أن تكون الصورة حقيقية. الشكل ٣: بنية المميز — الصورة المدخلة (1×28×28) تمر عبر طبقتي Conv2D

لماذا CNN بدل الطبقات الكثيفة؟

- المشتركة (Kernels) تنزلق عبر الصورة كاملة، فتكتشف الأنماط المحلية (حواف، منحنيات) بغض النظر عن موقعها. • الأوزان
- عدد المعاملات أقل بكثير مقارنة بالطبقات الكثيفة، مما يجعل التدريب أكفأ وأقل عرضة للحفظ الزائد (Overfitting).
- تبني تسلسلا هرميا من الميزات: الطبقات الأولى تكتشف حوفا بسيطة، والطبقات الأعمق تجمعها في أشكال أكثر تعقيدا.

دور كل مكون في المميز:

- قابلة للتعلم على الصورة (Filters) يستخرج الميزات المكانية عبر تمرير مرشحات: Conv2D •
- القيم السالبة، مما يمنع "موت" الخلايا العصبية ويحافظ على تدفق التدرجات أثناء التدريب التنافسي: LeakyReLU •
- يسمح بمرور تدرج صغير حتى عند عشوائيا جزءا من الخلايا العصبية أثناء التدريب، لمنع المميز من أن يصبح قويا جدا بسرعة تعيق تعلم المولد: Dropout •
- يعطل
- Dense يحول خرائط الميزات النهائية إلى متجه واحد الأبعاد ليصلح كمدخل لطبقة: Flatten •
- يحصّر خرج الطبقة الأخيرة بين 0 و 1، ليمثل هذا الرقم مدى ثقة المميز بأن الصورة حقيقية: Sigmoid •

٥. مقارنة: GAN التقليدي مقابل DCGAN

المعيار	GAN التقليدي	DCGAN
البنية	طبقات كثيفة بالكامل	التفافية (Conv2D / Conv2DTranspose) طبقات
استخراج الميزات	ضعيفة — تتعامل مع البيكسلات بشكل مستقل	قوية — تتعلم ميزات مكانية هرمية
جودة الصورة	ضبابية وضعيفة التفاصيل	أوضح وأكثر تماسكا
استقرار التدريب	غير مستقر، عرضة لانهيض الأنماط	استقرارا بفضل BatchNorm و LeakyReLU أكثر

٦. الخلاصة

DCGAN = GAN + بنية شبكات التفافية (CNN)

- جودة أعلى للصور الناتجة.
- تدريب أكثر استقرارا.
- تعلم أفضل للميزات المكانية.
- توليد صور محسن بشكل عام.